

| CATEGORÍA             | DESCRIPCIÓN                                                                                                                                                                                                                                                                                                         |
|-----------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| NOMBRE DEL DATASET    | Dataset de resultados educativos (tipo pruebas estandarizadas a nivel estudiante/colegio)                                                                                                                                                                                                                           |
| FUENTE                | <a href="https://www.datos.gov.co/Educaci-n/Resultados-nicos-Saber-11/kgxf-xxbe/about_data">https://www.datos.gov.co/Educaci-n/Resultados-nicos-Saber-11/kgxf-xxbe/about_data</a>                                                                                                                                   |
| TAMAÑO                | 7.110.000 registros x 51 variables                                                                                                                                                                                                                                                                                  |
| GRANURALIDAD          | Cada registro corresponde a un estudiante                                                                                                                                                                                                                                                                           |
| TIPO DE VARIABLES     | Catóricas (institucionales y socioeconómicas), numéricas (puntaje global) e identificadores                                                                                                                                                                                                                         |
| EJEMPLOS DE VARIABLES | Académicas: <i>punt_global</i> Institucionales: <i>cole_jornada</i> , <i>cole_bilingue</i><br>Socioeconómicas: <i>fami_estrato</i> , <i>fami_educacionpadre</i>                                                                                                                                                     |
| TIPO DE TAREA ML      | Dado que el dataset inicial contiene la variable Puntaje Global como Target candidato se puede pensar en un ejercicio de regresión. Sin embargo, el Target elegido será una variable generada a partir de los puntajes de cada prueba para categorizarla en 4 niveles que se describen en el desarrollo del trabajo |
| CALIDAD DE DATOS      | Presencia de valores nulos y categorías ambiguas (ej. “No aplica”), posible ruido catóricico                                                                                                                                                                                                                        |
| NIVEL DE GRANULARIDAD | Alto (nivel individual), permite modelado detallado                                                                                                                                                                                                                                                                 |
| CALIDAD DE DATOS      | Presencia de valores nulos, categorías ambiguas y posibles inconsistencias semánticas                                                                                                                                                                                                                               |
| COMPLEJIDAD ANALÍTICA | Alta cardinalidad en variables catóricas y heterogeneidad de fuentes de información                                                                                                                                                                                                                                 |
| LIMITACIONES CLAVE    | Ausencia de diccionario de datos, posible falta de representatividad                                                                                                                                                                                                                                                |
| RIESGOS METODOLÓGICOS | Sobreajuste, fuga de información (leakage) y dificultad de interpretabilidad en modelos complejos                                                                                                                                                                                                                   |
| RIESGOS ÉTICOS        | Potencial reproducción de sesgos socioeconómicos y uso sensible de predicciones en contextos educativos                                                                                                                                                                                                             |