

MODELO DE CLASIFICACIÓN PARA EL DESEMPEÑO ACADÉMICO EN RESULTADOS SABER 11

Autor: Jose Luis Bedoya Martinez | Asesor: Marco Tulio Teran de la Hoz

Maestría en Ciencias de los Datos y la Analítica • Escuela de Ciencias Aplicadas e Ingeniería • Universidad EAFIT • 2026

1. INTRODUCCIÓN Y PROBLEMA

El proyecto aborda un problema de **clasificación multiclase** sobre los resultados de la prueba Saber 11 en Colombia. El propósito principal es estimar el nivel de desempeño académico de los estudiantes utilizando exclusivamente variables institucionales, familiares y sociodemográficas.

Control de Fuga de Información (Data Leakage): Se excluyeron estrictamente del entrenamiento los puntajes por área y globales. Aunque sirvieron para construir el target, no pueden actuar como predictores si se desea evaluar la capacidad diagnóstica del contexto.

El reto metodológico central radica en el fuerte **desbalance natural** de los datos, donde los niveles extremos (especialmente el avanzado) cuentan con una representación muy baja en la población escolar.

2. DATASET Y VARIABLE OBJETIVO

El dataset original de 7.109.704 registros se delimitó a los periodos **2021 y 2022**, consolidando un conjunto final depurado de **566.241 registros** y 16 variables predictoras preliminares.

Distribución del Target (Variable Objetivo)

La variable objetivo se estructuró en cuatro niveles oficiales de desempeño académico:

N1: Insuficiente		18.46%
N2: Mínimo		47.46%
N3: Satisfactorio		30.08%
N4: Avanzado		4.00%

El desbalance es evidente: casi la mitad de los estudiantes se concentran en el nivel Mínimo (N2), mientras que solo un 4% alcanza el nivel Avanzado (N4).

3. METODOLOGÍA Y PIPELINE

Se diseñó un flujo robusto y reproducible de aprendizaje supervisado, integrando todas las transformaciones dentro de un único artefacto para prevenir contaminación entre particiones:

Pipeline de Preprocesamiento Integrado

- Variables Ordinales:** Imputación por moda, codificación con un orden lógico explícito y escalamiento.
- Variables Nominales:** Imputación por moda y transformación mediante **OneHotEncoder**.
- Consolidación:** Agrupación de categorías educativas de los padres en niveles interpretables, agregación de municipios y exclusión de la llave **estu_consecutivo** por carecer de capacidad de generalización.

4. EVALUACIÓN Y OPTIMIZACIÓN

La partición del dataset se realizó de manera **estrictamente estratificada** en conjuntos de Entrenamiento, Validación y Prueba (Test), asegurando la representatividad de las clases en cada etapa.

Métrica de Selección: Se priorizó el **F1 Macro** en lugar del Accuracy global. Esto evita favorecer falsamente a modelos que solo aciertan la clase mayoritaria (Mínimo) e ignoran las minoritarias.

Competencia de Modelos e Iteración Final

Se evaluaron inicialmente múltiples familias: KNN, SVM Lineal, Árbol de Decisión, Random Forest, CatBoost y XGBoost. El modelo ganador fue el **SVM Lineal**.

Posteriormente, se ejecutó una optimización avanzada mediante **GridSearchCV** con validación cruzada de 5 folds, refinando parámetros de regularización (**C** entre 0.001 y 100), penalización, tolerancia y balanceo de pesos de clase (**class_weight**).

5. RESULTADOS CLAVE

El modelo final optimizado se evaluó de forma definitiva sobre el conjunto de test independiente (**113.249 registros**):

0.4928

ACCURACY

0.4366

F1 MACRO

0.4917

F1 WEIGHTED

Desempeño Detallado por Clases (F1-Score)

Nivel de Desempeño	F1-Score	Interpretación del Patrón de Error
N1: Insuficiente	0.41	Desempeño moderado; fronteras difusas con N2.
N2: Mínimo	0.57	El rendimiento más alto debido al gran soporte de datos.
N3: Satisfactorio	0.44	Clasificaciones incorrectas concentradas en niveles adyacentes.
N4: Avanzado	0.33	La mayor dificultad por escasez crítica de registros.

Patrón de Error Crucial: La matriz de confusión demuestra que la mayoría de los fallos ocurren exclusivamente entre **niveles contiguos**. Esto confirma la naturaleza continua y transicional del rendimiento escolar, reflejando que los límites categóricos son difusos.

6. CONCLUSIONES Y DISCUSIÓN

- Ventaja Lineal:** El modelo lineal regularizado (**LinearSVC**) superó a modelos no lineales complejos debido a que el ***one-hot encoding*** genera un espacio de alta dimensionalidad idóneo para fronteras lineales estables.
- Techo de los Datos:** Las variables del entorno (hogar, colegio) imponen un límite predictivo. Para superar este techo se requiere integrar variables pedagógicas directas o trayectorias longitudinales.
- Uso Recomendado:** Es una herramienta sólida para el diseño y análisis macro de **políticas públicas**, pero **no debe emplearse** para decisiones deterministas o individuales de alto impacto.