

Entrega II: Comparación de modelos de clasificación para el desempeño académico en resultados Saber 11

*Nota aclaratoria: Este documento es la continuación del documento de la entrega 1.
Se continúa luego del capítulo 8 desarrollando lo realizado en esta fase*

Jose Luis Bedoya Martinez

Cc 78727981

Aprendizaje de Maquina Aplicado

Asesor, docente

Marco Tulio Teran de la Hoz



ESCUELA DE CIENCIAS APLICADAS E INGENIERÍA
MAESTRÍA EN CIENCIAS DE LOS DATOS Y LA ANALÍTICA

MEDELLÍN

2026

Contenido

1. Planteamiento del problema	3
2. Motivación y pertinencia del estudio	4
3. Descripción del conjunto de datos	4
4. Construcción del target	4
5. Etapa 00 - Obtención, filtrado y depuración inicial del dataset.....	5
5.1 Distribución final del target.....	5
6. Etapa 01 - Análisis exploratorio de datos	6
6.1 Valores nulos	6
6.2 Cardinalidad y variables constantes	6
6.3 Asociación entre variables categóricas	7
7. Etapa 02 - Preprocesamiento y baseline	9
7.1 Dataset modelable y separación train/test	10
7.2 Feature engineering y agrupación de categorías	11
7.3 Pipeline de preprocesamiento	11
7.4 Modelo baseline	11
8. Resultados del baseline en test.....	12
9. Etapa 03: Entrenamiento de Modelos	13
9.1. Ajustes para el entrenamiento:	13
9.2. Modelos a entrenar	13
9.3.Tuning de hiperparametros:	14
9.4. Resultados en train y val.....	14
9.5. Matriz de confusión mejor modelo	14
9.6. Conclusiones de la fase y trabajo posterior	17
10. Buenas prácticas implementadas	17
11. Conclusiones	18
11. Trabajo posterior y mejora del modelo	18
12. Cierre.....	18
13. Declaración de transparencia en el uso de la IA	18

Resumen

El trabajo desarrollado aborda un problema de clasificación multiclase sobre resultados Saber 11, con el objetivo de estimar el nivel de desempeño de un estudiante a partir de variables institucionales, familiares y sociodemográficas, excluyendo información directamente asociada al resultado de la prueba para evitar fuga de información. El flujo construido parte de una base original de 7.109.704 registros y 51 variables, aplica reglas de negocio para acotar el período 2021-2022, construye el target a partir del puntaje, elimina registros repetidos por estu_consecutivo y finaliza con un dataset modelable de 566.241 registros. Posteriormente se realiza un EDA orientado a calidad de datos, cardinalidad, valores nulos, asociación entre variables categóricas y selección de columnas. Finalmente, se implementa un pipeline reproducible de preprocesamiento y un baseline de regresión logística One-vs-One, evaluado sobre test antes de guardar el modelo. El baseline alcanza accuracy de 0,3958, F1 macro de 0,3767 y F1 weighted de 0,4002, resultados que constituyen una línea base inicial y dejan abierta la fase de mejora con modelos como CatBoost, Random Forest y XGBoost.

Elemento	Resultado principal
Fuente	Resultados Únicos Saber 11 - Datos Abiertos Colombia
Base original	7.109.704 registros y 51 variables
Período modelado	2021 y 2022
Dataset final luego de depuración inicial	566.241 registros y 33 columnas
Target	Nivel de desempeño: Insuficiente, Mínimo, Satisfactorio y Avanzado
Modelo baseline	Regresión Logística con estrategia One-vs-One
Métricas test	Accuracy 0,3958 F1 macro 0,3767 F1 weighted 0,4002

1. Planteamiento del problema

La calidad de la educación en Colombia es un tema central para el desarrollo social, económico y territorial. Existe una percepción extendida según la cual los estudiantes de capitales o grandes centros urbanos cuentan con mejores condiciones para acceder a una educación de calidad y, por tanto, para obtener mejores resultados en pruebas estandarizadas. Sin embargo, reducir el desempeño académico a la ubicación geográfica resulta insuficiente: el rendimiento de un estudiante puede estar influenciado por múltiples factores institucionales, familiares, socioeconómicos y personales.

En este contexto, las Pruebas Saber 11 representan una fuente de información valiosa, porque permiten observar resultados comparables a nivel nacional y con una granularidad individual. El dataset seleccionado integra variables asociadas al establecimiento educativo, al entorno familiar y a características del estudiante, además de puntajes por componente y puntaje global. El problema planteado consiste en construir un modelo de clasificación capaz de estimar el nivel de desempeño de un estudiante a partir de dichas características, sin utilizar variables que revelen de forma directa el resultado de la prueba.

Desde el punto de vista metodológico, el trabajo transforma un resultado originalmente numérico en un problema de clasificación multiclase. Esta decisión permite representar el desempeño en niveles interpretables y evita tratar el puntaje como una variable continua cuando, en la práctica, se expresa en valores discretos y se interpreta por rangos de desempeño.

2. Motivación y pertinencia del estudio

La motivación principal del trabajo es doble. En primer lugar, el tema tiene relevancia social: identificar patrones asociados al desempeño académico puede contribuir a formular preguntas más precisas sobre brechas educativas, condiciones institucionales y factores familiares que inciden en los resultados. No obstante, este tipo de análisis debe realizarse con cautela, porque variables socioeconómicas o territoriales pueden inducir interpretaciones sesgadas si se usan para justificar desigualdades en lugar de comprenderlas y mitigarlas.

En segundo lugar, el dataset plantea un reto técnico interesante para aprendizaje de máquina: predominan variables categóricas, algunas con alta cardinalidad, valores faltantes, categorías poco frecuentes y relaciones fuertes entre variables. Esto exige un diseño cuidadoso de preprocesamiento, selección de columnas, codificación y validación para evitar modelos frágiles o con fuga de información.

3. Descripción del conjunto de datos

El conjunto de datos corresponde a registros individuales de resultados Saber 11 disponibles en el portal de Datos Abiertos Colombia. Cada fila representa el resultado de un estudiante en un período determinado, por lo que la unidad de análisis es el examinado. La base original contiene 7.109.704 registros y 51 variables, incluyendo información del colegio, datos de residencia y presentación, características familiares, variables de acceso a bienes y servicios del hogar, puntajes por área y puntaje global.

Dimensión	Descripción
Granularidad	Cada registro representa el resultado de un estudiante en una aplicación de la prueba.
Variables institucionales	Jornada, naturaleza, calendario, carácter, ubicación y condiciones del establecimiento educativo.
Variables familiares	Educación de padre y madre, estrato, personas y cuartos en el hogar, acceso a computador, internet, lavadora o automóvil.
Variables del estudiante	Tipo de documento, genero, municipio/departamento de residencia y presentación, nacionalidad y otras condiciones.
Variables de resultado	Puntajes por prueba, puntaje global y desempeño en inglés; usadas para construir el target y luego eliminadas por riesgo de leakage.

Una decisión clave del trabajo fue excluir del entrenamiento las variables de puntaje y desempeño derivadas directamente del resultado de la prueba. Estas variables son útiles para construir el target, pero no deben incorporarse como predictoras porque inducirían fuga de información: el modelo estaría aprendiendo a predecir el nivel de desempeño a partir de variables que ya contienen el resultado que se desea estimar.

4. Construcción del target

La variable objetivo se construye a partir de la interpretación del desempeño académico en cuatro niveles. Aunque el puntaje global es numérico, se decidió abordar el problema como clasificación porque el interés del trabajo no es estimar un número exacto, sino ubicar al estudiante en un nivel de desempeño interpretable. El target final queda definido en cuatro clases: Nivel 1: Insuficiente, Nivel 2: Mínimo, Nivel 3: Satisfactorio y Nivel 4: Avanzado*

Nivel	Etiqueta	Rango interpretativo
-------	----------	----------------------

1	Insuficiente	0 a 40 puntos
2	Mínimo	41 a 55 puntos
3	Satisfactorio	56 a 70 puntos
4	Avanzado	71 a 100 puntos

En la etapa de obtención del dataset se calculó una variable intermedia de puntaje y, con base en ella, se asignó el nivel correspondiente. Posteriormente, las columnas de puntajes individuales y puntaje global fueron eliminadas del conjunto de variables predictoras para conservar la integridad metodológica del experimento.

* Esta clasificación se hizo basado en lo contenido en: <https://icfesinteractivo.info/interpretar-resultados-del-icfes/>

5. Etapa 00 - Obtención, filtrado y depuración inicial del dataset

El notebook 00_ObtenerDataset implementa la primera fase del flujo de trabajo. Dado el tamaño original de la base, se aplicaron reglas de negocio antes del EDA con el fin de obtener un dataset manejable y coherente con el objetivo del proyecto. La primera regla consistió en conservar los periodos 2021 y 2022, al considerarse una ventana más reciente y posterior a los momentos más críticos de la pandemia. La segunda regla consistió en conservar los registros de estudiantes activos esto es, pruebas realizadas por estudiantes y no por población particular.

Paso	Resultado
Lectura de base original	7.109.704 registros procesados.
Filtro por período 2021-2022	1.101.465 registros conservados.
Conversión de puntajes y construcción del target	4.105 registros eliminados por puntajes nulos, no convertibles o negativos.
Dataset previo a eliminación de duplicados	1.097.360 registros y 33 columnas.
Control de duplicados por estu_consecutivo	531.119 registros eliminados; no quedaron duplicados restantes.
Dataset final exportado	566.241 registros y 33 columnas.

La duplicidad de registro se definió a partir de la columna estu_consecutivo. Al tratarse de un identificador del examinado, la aparición de dos o más registros con el mismo valor se consideró un riesgo de repetición. Conservar estos registros podría sesgar las frecuencias de clase e inflar el desempeño del modelo si un mismo estudiante apareciera de forma repetida en entrenamiento y prueba. Después de este procedimiento, el notebook valido que no quedaran duplicados por esta llave.

5.1 Distribución final del target

Clase	Registros	Porcentaje
Nivel 2: Mínimo	268.741	47,46%
Nivel 3: Satisfactorio	170.346	30,08%
Nivel 1: Insuficiente	104.523	18,46%

Nivel 4: Avanzado	22.631	4,00%
-------------------	--------	-------

Figura 1. Distribución de la variable objetivo después de la depuración inicial.

La distribución evidencia un problema multiclase con desbalance. La clase mayoritaria es Nivel 2: Mínimo, mientras que Nivel 4: Avanzado representa solo el 4,00% de los registros. Por esta razón, el uso exclusivo de accuracy puede resultar insuficiente; se incorpora F1 macro para observar el desempeño promedio entre clases y F1 weighted para ponderar por soporte.

6. Etapa 01 - Análisis exploratorio de datos

El notebook 01_EDA desarrolla un análisis exploratorio orientado a preparar decisiones de preprocesamiento y modelado. El enfoque no se limita a graficar distribuciones, sino que busca establecer criterios técnicos para conservar, imputar, agrupar o eliminar variables. Dado que el dataset está dominado por variables categóricas, el EDA se centra en valores nulos, cardinalidad, variables constantes o casi constantes, distribución del target y asociación entre variables categóricas.

6.1 Valores nulos

La variable con mayor proporción de valores faltantes fue cole_bilingue, con 102.581 nulos, equivalentes al 18,12% de los registros. Las demás variables con nulos relevantes se ubicaron por debajo del 7%, lo cual favorece una estrategia de imputación en lugar de eliminación masiva de registros. Dado que la mayoría de estas variables son categóricas, se definió la moda como estrategia de imputación dentro del pipeline de preprocesamiento.

Variable	Nulos	Porcentaje
cole_bilingue	102.581	18,12%
fami_estratovivienda	37.482	6,62%
fami_tieneinternet	33.074	5,84%
fami_educacionmadre	32.446	5,73%
fami_educacionpadre	32.320	5,71%
fami_tieneautomovil	25.858	4,57%
fami_cuartoshogar	24.959	4,41%
fami_tienelavadora	24.864	4,39%
fami_tienecomputador	24.778	4,38%
fami_personashogar	24.062	4,25%
cole_caracter	23.569	4,16%

Figura 2. Variables con valores nulos identificadas en el EDA.

6.2 Cardinalidad y variables constantes

La cardinalidad se analizó como el número de valores únicos por columna. Este diagnóstico es especialmente importante en variables categóricas, porque una codificación one hot sobre columnas de alta cardinalidad puede expandir excesivamente la dimensionalidad del modelo. Además, las columnas constantes o casi constantes no aportan variabilidad y pueden eliminarse sin pérdida sustancial de información para el aprendizaje.

Categoría del diagnóstico	Variables identificadas
Variable constante	estu_estudiante

Variables casi constantes	estu_estadoinvestigacion, estu_privado_libertad, estu_nacionalidad, estu_pais_reside,
Alta cardinalidad	estu_consecutivo, estu_mcpio_reside, cole_mcpio_ubicacion, estu_mcpio_presentacion, estu_pais_reside, estu_nacionalidad
Media cardinalidad	estu_depto_reside, cole_depto_ubicacion, estu_depto_presentacion, estu_tipodocumento, fami_educacionpadre, fami_educacionmadre
Baja cardinalidad	19 variables, principalmente institucionales, familiares y binarias de acceso a bienes/servicios

Figura 3. Variables categóricas con mayor cardinalidad.


6.3 Asociación entre variables categóricas

Como el dataset este compuesto principalmente por variables categóricas, no resulta adecuado aplicar correlación de Pearson entre predictores. En su lugar se utilizó la V de Cramér como medida de asociación entre variables categóricas. El procedimiento implementado recorrió pares de variables y, cuando la asociación superaba 0,70, marcó la variable con menor asociación frente al target como candidata a eliminar. Este criterio se empleó como mecanismo de reducción de redundancia, no como regla automática absoluta; por ello, algunas decisiones se refinaron con criterio de negocio.


Criterio	Decisión aplicada
Medida de asociación	V de Cramér para pares de variables categóricas.
Umbral de alta asociación	0,70.
Criterio de desempate	Se conserva la variable con mayor asociación frente al target.
Validación conceptual	Las candidatas se revisan con criterio de negocio antes de exportar el listado final.

Figura 4. Matriz de asociación V de Cramér después de depurar variables redundantes.

En un primer análisis de la asociación se obtuvo la siguiente matriz:



Se observan regiones que describen alta asociación. Una vez realizado el procedimiento y volviendo a realizar la matriz con las columnas que se conservaron la matriz de asociación queda así:



El EDA generó inicialmente un conjunto de variables candidatas a eliminación por alta asociación y por baja contribución informativa. Después de la revisión conceptual, se conservaron algunas variables que, aunque aparecían asociadas con otras, podían aportar valor interpretativo o predictivo. El archivo final Columnas a Eliminar.csv fue exportado para ser usado por el notebook de preprocesamiento.

Tipo de criterio	Variables principales
Eliminadas por asociación/redundancia o por baja información	cole_area_ubicacion, cole_depto_presentacion, cole_depto_reside, cole_pais_reside, cole_sede_principal, cole_estadoinvestigacion, cole_privado_libertad, estu_mcpio_presentacion, estu_nacionalidad, fami_tieneautomovil, fami_tienelavadora, estu_mcpio_reside, estu_estudiante, estu_privado_libertad
Conservadas por criterio de negocio pese a aparecer como candidatas	cole_naturaleza, cole_genero, fami_tieneinternet, cole_calendario
Eliminada adicionalmente en preprocesamiento	período

7. Etapa 02 - Preprocesamiento y baseline

El notebook 02_Preprocesamiento implementa el flujo reproducible de entrenamiento. La decisión más importante fue integrar las transformaciones dentro de un Pipeline de scikit-learn para evitar fuga de información. De esta manera, las imputaciones, codificaciones, escalamiento y transformaciones aprendidas se ajustan únicamente con X_train y luego se aplican a X_test mediante el mismo pipeline.

7.1 Dataset modelable y separación train/test

A partir del dataset depurado, se eliminaron las columnas definidas en el archivo externo y también la variable período. El identificador estu_consecutivo se mantuvo como control de duplicados, pero se excluyó de X para evitar que el modelo aprendiera sobre una llave sin valor generalizable.

Elemento	Resultado
Columnas eliminadas efectivamente	15 columnas, incluyendo período.
Registros después de eliminar columnas y validar duplicados	566.241 registros.
Columnas finales en df_model	18 columnas, incluyendo target e identificador.
Matriz X	566.241 registros y 16 variables predictoras.
Vector y	566.241 etiquetas.
Train	452.992 registros.
Test	113.249 registros.
Estrategia de partición	80/20 con estratificación por target.

Una vez finalizado el proceso de Split se conservan los porcentajes de cada clase en el train y en el test:

Distribución y_train:	
	porcentaje_train
target	
Nivel 2: Mínimo	47.46
Nivel 3: Satisfactorio	30.08
Nivel 1: Insuficiente	18.46
Nivel 4: Avanzado	4.00
Distribución y_test:	
	porcentaje_test
target	
Nivel 2: Mínimo	47.46
Nivel 3: Satisfactorio	30.08
Nivel 1: Insuficiente	18.46
Nivel 4: Avanzado	4.00

7.2 Feature engineering y agrupación de categorías

El pipeline incluyo una etapa de feature engineering para crear la variable Mayor edad a partir de estu_tipodocumento. Cuando el documento es CC se asigna mayor de edad, cuando es TI se asigna Menor de edad y en cualquier otro caso se asigna No definido. Luego se elimina estu_tipodocumento para no duplicar la información original.

También se agruparon categorías en variables de educación de padre y madre para reducir dispersión semántica y representar niveles educativos ordenados: Ninguna, Primaria, Secundaria, Técnico, Profesional y Postgrado. La variable cole_mcpio_ubicacion se agrupo en categorías territoriales: Principal, Intermedia, Pequeña y Otra.

Variable / transformación	Tratamiento aplicado
Mayor edad	CC -> mayor de edad; TI -> Menor de edad; otros -> No definido.
fami_educacionpadre y fami_educacionmadre	Agrupación de categorías educativas y posterior ordinal encoding.
cole_mcpio_ubicacion	Agrupación en Principal, Intermedia, Pequeña u Otra.
Variables con nulos	Imputación con moda dentro del pipeline.
Variables ordinales	OrdinalEncoder con categorías definidas y manejo de desconocidos.
Variables nominales	OneHotEncoder con handle_unknown="ignore".

7.3 Pipeline de preprocesamiento

El pipeline final integra cuatro etapas: feature engineering, agrupación de categorías, preprocesamiento y clasificador. Las variables ordinales fueron imputadas por moda, codificadas con orden explícito y escaladas. Las variables nominales fueron imputadas por moda y codificadas mediante one hot encoding. Esta arquitectura garantiza que el conjunto de prueba sea transformado con los parámetros aprendidos desde entrenamiento, sin recalcular modas, categorías o escaladores sobre test.

Grupo de variables	Columnas
Ordinales	fami_estratovivienda, fami_educacionmadre, fami_educacionpadre, fami_cuartoshogar, fami_personashogar
Nominales	cole_bilingue, cole_calendario, cole_caracter, cole_genero, cole_jornada, cole_mcpio_ubicacion, cole_naturaleza, estu_genero, fami_tienecomputador, fami_tieneinternet, Mayor edad
Variables después del preprocesamiento	38 variables transformadas.

La verificación explícita del notebook mostró que X_train paso de 452.992 x 16 a 452.992 x 38, y X_test paso de 113.249 x 16 a 113.249 x 38. La igualdad en el número final de columnas confirma que el pipeline aplico transformaciones consistentes a entrenamiento y prueba.

7.4 Modelo baseline

Como modelo inicial se utilizó una regresión logística multiclase bajo estrategia One-vs-One. Esta configuración entrena clasificadores binarios para pares de clases y luego integra sus decisiones para resolver el problema multiclase. Se empleó `class_weight="balanced"` para compensar parcialmente el desbalance del target, especialmente relevante por la baja representación de la clase Nivel 4: Avanzado.

Parámetro / componente	Configuración
Clasificador base	LogisticRegression
Estrategia multiclase	OneVsOneClassifier
Solver	saga
Penalización	L2
C	1,0
max_iter	500
class_weight	balanced
Evaluación	Accuracy, F1 macro, F1 weighted y matriz de confusión en test

8. Resultados del baseline en test

Las métricas se calcularon sobre el conjunto de prueba antes de guardar el modelo. Este punto es importante porque confirma que el artefacto final corresponde a un pipeline ya evaluado y que el resultado reportado no proviene de datos de entrenamiento.

Métrica	Valor en test	Lectura metodológica
Accuracy	0,3958	Aproximadamente 39,6% de aciertos globales.
F1 macro	0,3767	Promedio no ponderado entre clases; evidencia margen de mejora en clases minoritarias.
F1 weighted	0,4002	Promedio ponderado por soporte; cercano al accuracy por el desbalance de clases.
Tamaño train	452.992	Datos usados para ajustar transformaciones y modelo.
Tamaño test	113.249	Datos usados para evaluación final.

Clase	Precisión	Recall	F1-score	Soporte
Nivel 1: Insuficiente	0,35	0,61	0,45	20.905
Nivel 2: Mínimo	0,56	0,32	0,41	53.749
Nivel 3: Satisfactorio	0,41	0,35	0,38	34.069
Nivel 4: Avanzado	0,17	0,68	0,28	4.526
Macro avg	0,37	0,49	0,38	113.249
Weighted avg	0,46	0,40	0,40	113.249

Figura 5. Matriz de confusión final en el conjunto de prueba.

El baseline cumple la función de establecer una primera línea de referencia, no de cerrar el problema. La matriz de confusión y el reporte de clasificación indican que el modelo logra capturar parte de la estructura del problema, pero presenta limitaciones para separar adecuadamente los niveles intermedios y para manejar la clase minoritaria. El recall alto en Nivel 4: Avanzado, combinado con baja precisión, sugiere que el modelo tiende a asignar esta clase en casos donde no siempre corresponde. En contraste, la clase Nivel 2: Mínimo tiene mayor precisión, pero recall reducido, lo que evidencia confusiones con otras categorías.

Estos resultados son coherentes con un baseline lineal sobre un problema donde es probable que existan relaciones no lineales, interacciones entre variables categóricas y efectos territoriales o socioeconómicos complejos. Por tanto, el baseline resulta útil como punto de comparación para modelos posteriores, pero no debe interpretarse como el mejor desempeño alcanzable.

9. Etapa 03: Entrenamiento de Modelos

9.1. Ajustes para el entrenamiento:

Para esta siguiente fase, donde buscaremos el mejor modelo de varias opciones disponibles, requerimos realizar algunos ajustes que permitan desarrollar lo requerido. En primer lugar, se requiere obtener un conjunto de datos de validación que nos permita ajustar los hiper parámetros durante el entrenamiento. Esto es, X y Y tendrán un set de datos en train con el 60% de los datos, un set de datos para validación con un 20% de los datos y el set de datos para test con el 20% restante.

La codificación numérica del target permite compatibilidad con los algoritmos de clasificación y conserva trazabilidad interpretativa entre el número asignado y el nivel de desempeño. Sin embargo, los modelos evaluados tratan la salida como una clasificación multiclase, no como una regresión ordinal. Por ello, la codificación no debe interpretarse como una distancia lineal entre niveles, sino como una representación controlada y verificable de las clases

9.2. Modelos a entrenar

En esta iteración de entrenamiento probaremos los modelos:

- KNN para clasificación
- SVM para clasificación
- Tree decisión
- Random Forest
- Catboost
- XGBoost.

Con esto se pretende tener resultados con diferentes metodologías de abordaje para la clasificación, pero con una mayor componente de algoritmos basados en arboles que los lineales o de distancias. Esto, tienen como sustento técnico, el hecho de que estamos trabajando con un dataset puramente categórico donde los arboles han mostrado mejor desempeño

9.3. Tuning de hiperparámetros:

Evaluar un conjunto de modelos requiere hallar los hiper parámetros correctos más allá de los que vienen considerados por defecto en su implementación. Ya hemos visto que determinar correctamente los valores de los hiper parámetros son un factor clave de éxito en el desempeño final del modelo entrenado.

En este caso, usamos GridSearchCV con 5 folds para la validación cruzada. Se generan las siguientes combinaciones por modelo:

```
knn: 12 combinaciones x 5 folds = 60 ajustes
svm_lineal: 3 combinaciones x 5 folds = 15 ajustes
decision_tree: 18 combinaciones x 5 folds = 90 ajustes
random_forest: 8 combinaciones x 5 folds = 40 ajustes
catboost: 8 combinaciones x 5 folds = 40 ajustes
xgboost: 8 combinaciones x 5 folds = 40 ajustes
```

Si bien este método es ampliamente usado genera un reto en el procesamiento necesario, pues para este caso se requiere el entrenamiento de 285 modelos diferentes lo cual implica dedicar varias horas solo para establecer los hiper parámetros.

9.4. Resultados en train y val

A continuación, se presenta la tabla con los mejores resultados de cada modelo:

modelo	tipo_busqueda	cv_best_f1_macro	val_accuracy	val_f1_macro	val_f1_weighted	best_params	tiempo_segundos
SVM lineal - LinearSVC	GridSearchCV_5fold	0.433766	0.493254	0.436441	0.492760	{"classifier__C": 0.1}	63.059696
Random Forest Classifier	GridSearchCV_5fold	0.409241	0.465218	0.415054	0.469835	{"classifier__max_depth": 20, "classifier__max...	1499.615650
XGBoost Classifier	GridSearchCV_5fold	0.398187	0.546782	0.401415	0.514144	{"classifier__colsample_bytree": 0.8, "classif...	704.475932
CatBoost Classifier	GridSearchCV_5fold	0.401480	0.423972	0.400918	0.429289	{"classifier__depth": 6, "classifier__iteratio...	772.136675
Decision Tree Classifier	GridSearchCV_5fold	0.381803	0.401605	0.381374	0.406466	{"classifier__criterion": "gini", "classifier__...	208.029386
KNN Classifier	GridSearchCV_5fold	0.377243	0.504777	0.378605	0.481911	{"classifier__metric": "manhattan", "classifie...	13964.307752
Baseline Regresión Logística One-vs-One	baseline_sin_gridsearch	NaN	0.394762	0.375356	0.399733	{}	NaN

En este caso, el mejor desempeño se encuentra en SVM con un C de 0.1.

Si bien aún el modelo está lejos de ser considerado bueno, se logra un aumento significativo frente al baseline pasado de una accuracy de 0.39 en regresión logística a 0.49 de accuracy en validación y un f1 de 0.43.

Otro aspecto importante es el costo del procesamiento: mientras SVM tarda poco mas de 1 minuto, el random forest tarda casi 25 minutos y KNN tarda casi 4 horas teniendo, además, el peor desempeño.

9.5. Matriz de confusión mejor modelo

El mejor modelo es entrenado esta vez con los datos de train y val para obtener un modelo final y realizar la fase de test.

Una vez realizado esto, y probando en el set de datos de test:

*** Métricas finales en TEST

	modelo_final	dataset_evaluacion	accuracy	f1_macro	f1_weighted	n_train_val	n_test	
0	SVM lineal - LinearSVC	test	0.492764	0.436605	0.491738	452992	113249	


Reporte de clasificación en TEST:

	precision	recall	f1-score	support
Nivel 1: Insuficiente	0.43	0.38	0.41	20905
Nivel 2: Mínimo	0.55	0.59	0.57	53749
Nivel 3: Satisfactorio	0.47	0.41	0.44	34069
Nivel 4: Avanzado	0.26	0.45	0.33	4526
accuracy			0.49	113249
macro avg	0.43	0.46	0.44	113249
weighted avg	0.50	0.49	0.49	113249

Mapeo usado para interpretar las métricas:

	codigo_target_modelo	etiqueta_original
0	1	Nivel 1: Insuficiente
1	2	Nivel 2: Mínimo
2	3	Nivel 3: Satisfactorio
3	4	Nivel 4: Avanzado

En este nivel podemos observar mejor la clasificación de cada clase observando que el mejor f1 se alcanza el nivel 2: Mínimo y la de menor f1 se encuentra en nivel 4: Avanzado.



La matriz de confusión nos permite observar hallazgos importantes:

- Cuando el modelo se equivoca, lo hace en clases adyacentes, esto es, tiende a clasificar incorrectamente Mínimo con Insuficiente y del mismo modo, aunque a menor nivel, Mínimo con satisfactorio
- Esto puede tener varias lecturas: en principio, se puede inferir que el modelo requiere un mejor entrenamiento para lograr generalizar correctamente. Los resultados sugieren que las variables disponibles no son suficientes para separar con alta precisión los niveles de desempeño. Esto puede deberse a que el desempeño académico depende de factores adicionales no observados en el dataset, como trayectoria escolar, calidad pedagógica, motivación, asistencia, preparación específica para la prueba, condiciones emocionales o características individuales no registradas
- Aunque inicialmente se esperaba que los modelos basados en árboles tuvieran ventaja por la naturaleza categórica del conjunto de datos, los resultados empíricos muestran que, bajo la representación actual basada en codificación ordinal y one-hot encoding, el mejor desempeño lo obtiene un modelo lineal SVM. Esto sugiere que la transformación de las variables genera un espacio

de características donde una frontera lineal regularizada logra generalizar mejor que los modelos no lineales evaluados.

9.6. Conclusiones de la fase y trabajo posterior

En esta fase hemos logrado superar el baseline gracias a buenas practicas de implementación:

- Separa los datos en train, val y test, evitando usar el conjunto de prueba durante la selección del modelo.
- Codifica el target de forma numérica antes del split, con un mapeo único y verificable: Nivel 1 -> 1, Nivel 2 -> 2, Nivel 3 -> 3 y Nivel 4 -> 4.
- Mantiene la coherencia de esa codificación en train, val, test, GridSearchCV, evaluación final e inferencia.
- Mantiene el preprocesamiento de variables predictoras dentro del Pipeline, por lo que imputación, codificación y escalamiento se aprenden solo con los datos permitidos en cada etapa.
- Usa GridSearchCV con StratifiedKFold de 5 folds para comparar hiperparámetros dentro de cada familia de modelos.
- Evalúa KNN, SVM lineal, árbol de decisión, Random Forest, CatBoost y XGBoost bajo el mismo flujo de preprocesamiento.
- Selecciona el mejor modelo usando F1 macro en validación, una métrica pertinente para clasificación multiclase.
- Reentrena el modelo seleccionado con train + val y evalúa una sola vez sobre test.
- Guarda el pipeline completo como artefacto reproducible con joblib, incluyendo métricas, columnas usadas, configuración de split, resultados de la búsqueda y mapeo del target.

Con esto se evita el principal riesgo metodológico: que información del conjunto de validación o prueba influya en el aprendizaje de imputadores, codificadores, escaladores, hiperparámetros o parámetros finales del modelo. También se evita que los modelos reciban etiquetas textuales como target, lo cual reduce errores de compatibilidad y mantiene trazabilidad en la interpretación de resultados

10. Buenas prácticas implementadas

- Construcción del target antes de eliminar variables de puntaje, evitando que estas ingresen al entrenamiento como predictoras.
- Eliminación de registros repetidos usando estu_consecutivo como identificador del examinado.
- Separación train/test antes de ajustar el pipeline de preprocesamiento.
- Imputación, codificación y escalamiento dentro del Pipeline, evitando fuga de información.
- Uso de estratificación en train/test para conservar la distribución de clases.
- Exclusión de identificadores como estu_consecutivo del conjunto de variables predictoras.
- Reporte de métricas en test antes del guardado del modelo final.
- Conservación del pipeline completo como artefacto, permitiendo inferencia posterior con las mismas transformaciones.

11. Conclusiones

1. El flujo completo permitió pasar de una base masiva y heterogénea a un dataset modelable, documentado y reproducible. La reducción no se hizo de manera arbitraria: respondió a criterios de período, construcción del target, eliminación de columnas con riesgo de leakage y control de duplicados.
2. El EDA evidenció que el reto principal no estaba en variables numéricas sino en el tratamiento de variables categóricas: valores nulos, alta cardinalidad, categorías redundantes y asociaciones fuertes entre predictores.
3. La V de Cramér fue una decisión metodológicamente adecuada para analizar asociación entre variables categóricas. Su uso permitió identificar redundancias y construir un listado de columnas candidatas a eliminación, posteriormente ajustado con criterio de negocio.
4. El pipeline de preprocesamiento quedo correctamente integrado al modelo. Esto garantiza que X_{test} se transforme con los parámetros aprendidos desde X_{train} y evita leakage por imputación o codificación previa sobre todo el dataset.
5. La regresión logística One-vs-One constituye una línea base razonable para comparación. Sin embargo, sus métricas en test muestran que el problema requiere modelos más expresivos y posiblemente estrategias adicionales de tratamiento del desbalance y de codificación de variables categóricas.
6. El baseline no debe presentarse como solución final, sino como punto de partida cuantitativo. Su valor está en fijar una referencia inicial: accuracy 0,3958, F1 macro 0,3767 y F1 weighted 0,4002.
7. La familia de modelo que presenta mejor desempeño es la lineal
8. El modelo final se “equivoca” al clasificar categorías adyacentes lo que puede indicar que se puede mejorar a través de ciertos ajustes o que se empieza a evidenciar un mecanismo subyacente donde las diferentes clases no tienen fronteras bien definidas

11. Trabajo posterior y mejora del modelo

La siguiente fase del trabajo debe ser una nueva iteración de lo presentado en esta entrega buscando afinar el modelo para obtener mejor desempeño. Se puede plantear la implementación de una red neuronal que nos permita establecer si el modelo posee una estructura compleja que requiere un nivel mayor para obtener una generalización aceptable.

12. Cierre

El trabajo logra cubrir todo el ciclo de entrenamiento de modelos implementando buenas prácticas que garantizan un resultado consistente y defendible en su metodología y rigor técnico

13. Declaración de transparencia en el uso de la IA

Durante el desarrollo de este trabajo se hizo uso de la IA como asistente en la construcción del código en Python. Las decisiones metodológicas, de abordaje del problema, de enfoque de solución y todo lo concerniente al saber propio del curso que estoy desarrollando fueron tomadas con mi criterio. La creación de un notebook 0 para reducir el problema, la categorización del target, el análisis de asociación, la manera de implementar la agrupación y la imputación, las reglas de cómo y cuándo realizar el Split del conjunto de datos, las métricas para el baseline y el modelo de regresión OVO fueron decisiones propias como estudiante y responsable del desarrollo del trabajo.

Finalmente, el presente documento fue el resultado de una versión inicial creada por mi y que tomó chatgpt para generar el documento inicial. Esta versión final fue revisada y ajustada en algunos aspectos por mi parte.