

Entrega III: Modelo de clasificación para el desempeño académico en resultados Saber 11

*Nota aclaratoria: Este documento es la continuación del documento de la entrega 1 y 2.
Se centra en tener la explicación de los resultados obtenidos y el mejor modelo*

Jose Luis Bedoya Martinez

Cc 78727981

Aprendizaje de Maquina Aplicado

Asesor, docente

Marco Tulio Teran de la Hoz



ESCUELA DE CIENCIAS APLICADAS E INGENIERÍA

MAESTRÍA EN CIENCIAS DE LOS DATOS Y LA ANALÍTICA

MEDELLÍN

2026

Contenido

1. Resumen 3

2. Metodología..... 3

 2.1 Construcción del dataset y del target 3

 2.2 Análisis exploratorio y selección de variables 4

 2.3 Pipeline de preprocesamiento y control de leakage 4

 2.4 Selección y optimización del modelo..... 4

3. Resultados..... 5

4. Discusión 7

5. Limitaciones 8

6. Recomendaciones 8

7. Conclusiones 9

8. Trabajos futuros 9

9. Declaración de transparencia en el uso de la IA 10

1. Resumen

El proyecto aborda un problema de clasificación multiclase sobre resultados Saber 11. El propósito fue estimar el nivel de desempeño de un estudiante a partir de variables institucionales, familiares y sociodemográficas, excluyendo del entrenamiento las variables que revelan directamente el resultado de la prueba. Esta exclusión fue una decisión central para evitar fuga de información, porque los puntajes por área y el puntaje global fueron usados para construir el target, pero no podían permanecer como predictores del modelo.

El flujo de trabajo partió de una base amplia de resultados Saber 11, se delimitó al periodo 2021-2022 y se depuró hasta obtener un dataset modelable de 566.241 registros. La variable objetivo quedó organizada en cuatro niveles de desempeño: Insuficiente, Mínimo, Satisfactorio y Avanzado. El conjunto final conserva un reto metodológico importante: el target está desbalanceado, especialmente porque el nivel Avanzado representa una proporción baja de los registros, mientras que el nivel Mínimo concentra la mayor parte de las observaciones.

Después del análisis exploratorio y de la construcción del pipeline de preprocesamiento, se compararon varias familias de modelos. La mejor alternativa fue un SVM lineal implementado con LinearSVC, elegido por F1 macro y no por accuracy. Esta decisión es relevante porque el problema no busca únicamente maximizar aciertos globales, sino mantener una lectura más equilibrada entre clases. El modelo final alcanzó en test accuracy de 0,4928, F1 macro de 0,4366 y F1 weighted de 0,4917. Estos resultados muestran una mejora frente al baseline y permiten cerrar el proyecto con un modelo reproducible, aunque todavía con desempeño moderado y margen claro de mejora.

2. Metodología

La metodología se desarrolló como un flujo reproducible de aprendizaje supervisado. Primero se realizó la obtención y depuración inicial del dataset, luego un EDA orientado a calidad de datos y selección de variables, después un pipeline de preprocesamiento y, finalmente, una fase de comparación y optimización de modelos. El criterio transversal fue mantener una separación estricta entre entrenamiento, validación y prueba para evitar que las decisiones del modelo se vieran influidas por información que debía permanecer no vista.

2.1 Construcción del dataset y del target

El dataset original fue filtrado para conservar los periodos 2021 y 2022. Después se construyó el target a partir del puntaje, transformando el resultado numérico en una etiqueta de cuatro niveles. Esta transformación tiene sentido para el proyecto porque el interés no era predecir un puntaje exacto, sino clasificar al estudiante en un nivel de desempeño interpretable. Una vez construido el target, las variables de resultado fueron retiradas de las variables predictoras para evitar leakage.

Elemento	Resultado consolidado
Base original	7.109.704 registros y 51 variables
Periodo modelado	2021 y 2022
Dataset final depurado	566.241 registros
Variables predictoras finales	16 variables antes del preprocesamiento
Target	Nivel 1: Insuficiente, Nivel 2: Mínimo, Nivel 3: Satisfactorio, Nivel 4: Avanzado
Estrategia de evaluación	train, validación y test con estratificación por target




Figura 1. Distribución del target después de la depuración inicial.

2.2 Análisis exploratorio y selección de variables

El EDA mostró que el problema estaba dominado por variables categóricas. Por eso no se usó una lectura basada en correlación de Pearson entre predictores, sino una revisión de cardinalidad, valores nulos, variables constantes o casi constantes y asociación categórica mediante V de Cramér. Este análisis permitió identificar redundancias y columnas de bajo aporte, pero la eliminación final no fue automática: algunas variables se conservaron por criterio conceptual, dado que podían aportar información interpretativa o predictiva.

Entre las decisiones más importantes estuvo tratar los valores nulos dentro del pipeline mediante imputación, agrupar categorías educativas de padre y madre en niveles interpretables, agrupar municipios de ubicación del colegio y crear una variable derivada de mayoría de edad a partir del tipo de documento. Estas transformaciones se incorporaron al pipeline para que el mismo flujo pudiera usarse en entrenamiento, evaluación e inferencia.

2.3 Pipeline de preprocesamiento y control de leakage

El pipeline fue diseñado para que imputación, codificación, escalamiento y entrenamiento se ejecutaran como una sola unidad. Las variables ordinales fueron imputadas por moda, codificadas con un orden explícito y escaladas. Las nominales fueron imputadas por moda y transformadas con OneHotEncoder. El identificador estu_consecutivo se usó para controlar duplicados, pero se excluyó de las variables predictoras, porque una llave no aporta capacidad de generalización.

En la fase de comparación de modelos, los datos fueron separados en train, validación y test. El conjunto de validación permitió comparar familias de modelos e hiperparámetros sin tocar test. El conjunto test se reservó hasta el cierre, cuando el modelo seleccionado fue reentrenado con train + validación y evaluado una sola vez.

2.4 Selección y optimización del modelo

En la Entrega 2 se evaluaron KNN, SVM lineal, árbol de decisión, Random Forest, CatBoost y XGBoost bajo el mismo pipeline. La selección se hizo con F1 macro, una métrica más adecuada que accuracy cuando hay varias clases y desbalance. Bajo este criterio, el SVM lineal fue el mejor modelo. Posteriormente, se desarrolló una iteración final enfocada únicamente en SVM, usando un GridSearchCV ampliado sobre LinearSVC y un afinamiento local alrededor del mejor valor de C encontrado.

La iteración final mantuvo las buenas prácticas del proyecto: el test permaneció aislado, el target se conservó codificado de forma trazable, el preprocesamiento siguió dentro del pipeline y la búsqueda se realizó con validación cruzada estratificada de cinco folds. Esta etapa no cambia el enfoque del proyecto, sino que profundiza sobre el modelo ganador para verificar si una búsqueda más amplia de regularización, penalización, tolerancia y balanceo de clases podía mejorar el desempeño.

Componente de la iteración final	Implementación
Modelo base	LinearSVC dentro del mismo pipeline de preprocesamiento
Búsqueda ampliada	Valores de C entre 0,001 y 100, penalización L1/L2, class_weight None/balanced y tolerancias 1e-4 y 1e-3
Validación	GridSearchCV con StratifiedKFold de 5 folds y F1 macro como scoring
Afinamiento local	Segunda búsqueda alrededor del mejor C encontrado
Evaluación final	Reentrenamiento con train + validación y evaluación final en test

3. Resultados

En la Entrega 2 se construyó el punto de comparación metodológico del proyecto: primero se estableció un baseline y después se realizó una competencia de modelos con validación cruzada. Esa fase permitió identificar que, bajo la representación actual de variables categóricas transformadas con codificación ordinal y one-hot encoding, el SVM lineal era la alternativa más equilibrada cuando el criterio de selección era F1 macro. Aunque otros modelos podían mostrar mejor accuracy, el SVM mantuvo mejor desempeño promedio entre clases, que era el criterio más pertinente para el problema planteado.

Luego se realizó una iteración adicional para mejorar el modelo seleccionado. Esta iteración no consistió en volver a comparar todas las familias, sino en profundizar sobre el SVM con un GridSearchCV más amplio y un afinamiento local. La razón de esta decisión fue técnica: una vez identificado el modelo más prometedor, tenía más sentido explorar con mayor detalle su regularización y configuración interna que reiniciar la competencia completa. De esa manera, la iteración final funcionó como un análisis de sensibilidad del modelo ganador.

Los resultados que se presentan a continuación corresponden únicamente al modelo final evaluado en test. Se omiten tablas comparativas de otros modelos para mantener el foco del reporte en la versión final seleccionada.

Métrica del modelo final	Valor en test
Modelo final	SVM lineal - LinearSVC
Accuracy	0,4928
F1 macro	0,4366
F1 weighted	0,4917
Registros usados en train + validación	452.992
Registros evaluados en test	113.249

Métricas finales del modelo SVM en test




Figura 2. Métricas finales del SVM lineal sobre el conjunto test.

La lectura de las métricas muestra un desempeño moderado. El accuracy cercano a 0,49 indica que el modelo acierta aproximadamente la mitad de los casos del conjunto de prueba. El F1 macro de 0,4366 es la métrica más importante para la decisión final, porque resume el desempeño promedio entre las cuatro clases sin permitir que la clase mayoritaria domine totalmente el resultado. El F1 weighted de 0,4917 confirma que el comportamiento global del modelo es consistente con el accuracy, pero también evidencia que la distribución de clases influye en la lectura agregada.

Clase	Precisión	Recall	F1-score	Soporte
Nivel 1: Insuficiente	0,43	0,38	0,41	20.905
Nivel 2: Mínimo	0,55	0,59	0,57	53.749
Nivel 3: Satisfactorio	0,47	0,41	0,44	34.069
Nivel 4: Avanzado	0,26	0,45	0,33	4.526
Macro avg	0,43	0,46	0,44	113.249
Weighted avg	0,50	0,49	0,49	113.249




Figura 3. Desempeño por clase del modelo final.




Figura 4. Matriz de confusión del SVM final sobre test.

La matriz de confusión permite ver que el mejor desempeño relativo se concentra en el Nivel 2: Mínimo, que además es la clase con mayor soporte. El Nivel 4: Avanzado presenta el F1-score más bajo, en parte porque tiene menos registros y porque sus fronteras con el nivel Satisfactorio no son completamente separables con las variables disponibles. También se observa que una proporción importante de errores ocurre entre niveles cercanos, especialmente entre Insuficiente, Mínimo y Satisfactorio. Este comportamiento es coherente con un problema donde el desempeño académico no cambia de manera abrupta entre niveles, sino por transiciones graduales.

4. Discusión

El mejor modelo es el SVM lineal implementado mediante LinearSVC. Esta elección no se hizo porque fuera el algoritmo más complejo ni el más reciente, sino porque fue el que mejor respondió al criterio metodológico del proyecto: F1 macro. En un problema multiclase y desbalanceado, la accuracy puede resultar engañosa, porque un modelo puede obtener un buen porcentaje global de aciertos concentrándose en la clase mayoritaria. El SVM, en cambio, mostró un comportamiento más equilibrado entre clases y por eso fue seleccionado como modelo final. Además, su costo computacional fue razonable frente a otras alternativas evaluadas, lo cual es importante en un proyecto desarrollado con recursos de Colab y con un volumen de datos considerable.

Los resultados son confiables desde el punto de vista metodológico, pero deben interpretarse con prudencia desde el punto de vista predictivo. Son confiables porque se construyeron con separación de datos en train, validación y test, con estratificación del target, con preprocesamiento dentro del pipeline y con evaluación final sobre un conjunto test que no participó en la selección del modelo. Esto reduce el riesgo de fuga de información y permite

afirmar que las métricas reportadas no provienen de una evaluación contaminada por el entrenamiento. Sin embargo, la confianza metodológica no significa que el modelo sea altamente preciso. El F1 macro de 0,4366 muestra que todavía hay dificultad para separar los cuatro niveles de desempeño, especialmente en las clases minoritarias o en las fronteras entre niveles. Por tanto, el resultado es defendible como cierre académico y como modelo reproducible, pero no debe presentarse como una solución predictiva definitiva para tomar decisiones individuales de alto impacto.

El desempeño del modelo se explica por una combinación de patrones del dataset y decisiones de representación. En primer lugar, el target está desbalanceado: Nivel 2: Mínimo concentra casi la mitad de los registros, mientras que Nivel 4: Avanzado representa una proporción mucho menor. Esto hace que el modelo aprenda con más facilidad los patrones de la clase mayoritaria y tenga más dificultad para generalizar sobre los extremos. En segundo lugar, las variables disponibles son indirectas: describen condiciones institucionales, familiares y sociodemográficas, pero no capturan por completo aspectos decisivos del desempeño académico como trayectoria escolar, preparación específica para la prueba, asistencia, motivación, calidad pedagógica o condiciones emocionales. En tercer lugar, la matriz de confusión muestra que los errores se presentan sobre todo entre clases adyacentes. Este patrón sugiere que el problema tiene una naturaleza parcialmente ordinal: Insuficiente, Mínimo, Satisfactorio y Avanzado representan niveles progresivos, pero el modelo fue formulado como clasificación multiclase, no como clasificación ordinal.

También es importante resaltar que el hecho de que un modelo lineal haya superado a modelos más complejos bajo F1 macro no debe interpretarse como una contradicción. Después del preprocesamiento, las variables categóricas se convierten en un espacio de alta dimensionalidad por efecto del one-hot encoding, y en ese espacio una frontera lineal regularizada puede generalizar mejor que modelos con mayor capacidad no lineal. En este caso, el SVM parece aprovechar esa representación sin sobreajustarse de manera marcada. La lectura más prudente es que el desempeño no depende de una sola variable, sino de patrones combinados entre características del colegio, condiciones del hogar, acceso a recursos y variables derivadas del estudiante, todo esto limitado por la información realmente disponible en la base.

5. Limitaciones

La principal limitación del proyecto es que las variables predictoras no contienen toda la información necesaria para explicar el desempeño académico. El dataset permite observar condiciones institucionales, familiares y sociodemográficas, pero no incluye variables pedagógicas profundas ni información longitudinal del estudiante. Por esta razón, existe un techo natural de desempeño que no se puede superar únicamente con más búsqueda de hiperparámetros.

Una segunda limitación es el desbalance de clases. Aunque se utilizó F1 macro como criterio de selección y se probaron configuraciones con balanceo, la baja proporción de Nivel 4: Avanzado sigue afectando la precisión y el F1 de esa clase. Además, la clasificación en cuatro niveles transforma un fenómeno continuo o gradual en categorías discretas, lo que puede hacer que registros cercanos al límite entre dos niveles sean difíciles de distinguir.

6. Recomendaciones

El modelo SVM es una solución reproducible y metodológicamente sólida, pero no es un sistema de decisión automática. Su mejor uso es analítico: ayudar a entender patrones asociados al desempeño y servir como base de comparación para modelos futuros. Cualquier uso del modelo debe evitar conclusiones deterministas sobre estudiantes o instituciones, porque el resultado académico depende de múltiples factores que no están completamente representados en los datos.

Desde el punto de vista técnico, se recomienda mantener el pipeline completo como artefacto único de inferencia, incluyendo transformaciones, codificaciones, escalamiento, modelo y mapeo del target. Esto evita inconsistencias entre entrenamiento y predicción.

Para mejorar el desempeño, se deben probar estrategias específicas para clases desbalanceadas, evaluar enfoques ordinales y realizar interpretabilidad con coeficientes del SVM o con métodos de explicación independientes. También sería útil evaluar si incorporar nuevas variables o fuentes de información mejora más el desempeño que aumentar la complejidad del modelo.

7. Conclusiones

El proyecto deja como conclusión útil que sí es posible construir un flujo reproducible para clasificar el desempeño académico a partir de variables no directamente asociadas al resultado de la prueba. El valor del trabajo no está solo en la métrica final, sino en la manera como se controló la fuga de información, se documentó la construcción del target, se depuraron variables y se separó adecuadamente el proceso de selección del proceso de evaluación final.

La comparación de modelos mostró que la selección de la métrica cambia la interpretación del mejor modelo. Si se hubiera elegido solo por accuracy, el proyecto habría favorecido un modelo con mejor acierto global aparente, pero con menor equilibrio entre clases. Al usar F1 macro, la decisión fue más coherente con el carácter multiclase y desbalanceado del problema. Así, el SVM lineal aparece como el mejor compromiso entre desempeño, estabilidad, costo computacional y trazabilidad.

La matriz de confusión deja otra conclusión relevante: el modelo no falla de manera completamente aleatoria. Buena parte de los errores se concentra entre niveles cercanos, lo cual indica que las clases tienen fronteras difusas. Esto aporta una lectura importante del problema educativo: los niveles de desempeño no son grupos totalmente separados desde las variables disponibles, sino estados que pueden estar conectados por condiciones comunes del contexto familiar e institucional.

Finalmente, el proyecto permite reconocer una conclusión metodológica: mejorar un modelo no siempre significa pasar a algoritmos más complejos. En este caso, un modelo lineal con una representación adecuada de variables categóricas logró el mejor resultado bajo la métrica principal. El esfuerzo futuro debería concentrarse tanto en nuevas estrategias de modelado como en enriquecer los datos y mejorar la interpretación del modelo.

8. Trabajos futuros

Para mejorar la solución haría falta avanzar en el tratamiento del desbalance. Se pueden explorar técnicas de ponderación más finas, calibración por clase, umbrales de decisión, submuestreo controlado o generación sintética, siempre evitando que estas técnicas introduzcan fuga de información. El objetivo sería mejorar el desempeño en Nivel 4: Avanzado sin deteriorar excesivamente las demás clases.

Un segundo frente a fortalecer es la interpretabilidad. Para que el modelo sea más útil, es necesario profundizar en qué variables o combinaciones de categorías empujan las predicciones hacia cada nivel. Esto puede hacerse con análisis de coeficientes del SVM sobre las variables transformadas, validación de estabilidad por folds y herramientas de explicación local.

Un tercer frente es el despliegue. Para poner la solución en producción se requiere realizar todas las tareas necesarias: limpiar el repositorio, definir un requirements.txt estable, guardar el pipeline final con joblib, crear un script de inferencia que reciba datos con el mismo esquema, validar entradas nuevas, registrar predicciones y monitorear desempeño. Además, se debería establecer un esquema de reentrenamiento periódico, por ejemplo anual, o bajo demanda cuando cambie la distribución de los datos. Antes de usarlo en decisiones reales, también sería necesario revisar sesgos, evaluar desempeño por subgrupos y documentar claramente que el modelo ofrece una predicción estadística, no una explicación causal ni una valoración definitiva del estudiante.

9. Declaración de transparencia en el uso de la IA

Durante el desarrollo de este trabajo se hizo uso de la IA como asistente en la construcción del código en Python. Las decisiones metodológicas, de abordaje del problema, de enfoque de solución y todo lo concerniente al saber propio del curso que estoy desarrollando fueron tomadas con mi criterio. La creación de un notebook 0 para reducir el problema, la categorización del target, el análisis de asociación, la manera de implementar la agrupación y la imputación, las reglas de cómo y cuándo realizar el Split del conjunto de datos, las métricas para el baseline y el modelo de regresión OVO fueron decisiones propias como estudiante y responsable del desarrollo del trabajo.

El presente documento fue el resultado de una versión inicial creada por mi y que tomó chatgpt para generar el documento inicial. Esta versión final fue revisada y ajustada en algunos aspectos por mi parte.

Para otros entregables como el poster solicitado se utilizó Gemini dándole como insumo el documento actual. Para la generación de las diapositivas se utiliza notebooklm tomando como Fuente este mismo trabajo final.